DCCS 410 | 빅데이터분산처리시스템

# KITTI 기반 자율주행 데이터 처리·인식 검증

Final Project Proposal · 2022271315 손한주 · 2026. 10. 21.

## 1. 프로젝트 목표 및 활용 데이터

자율주행 카메라·LiDAR·객체 정답을 연결하는 Spark 기반 병렬 처리 파이프라인을 구축한다. 거리·가림 정도·관측 포인트 수에 따른 데이터 특성을 분석하고, 원하는 조건의 장면을 검색하여 향후 인식 모델 평가에 재사용할 수 있도록 한다.

KITTI Object Detection의 정답이 제공되는 학습 장면 7,481개를 대상으로 왼쪽 카메라 이미지, LiDAR, 객체 라벨과 보정 정보를 사용한다. 공식 배포 패키지는 이미지 약 12GB, LiDAR 약 29GB이며 학습·시험 자료를 포함한다. 실제 처리 용량과 총 포인트 수는 수집 후 측정한다.

## 2. 빅데이터 처리 방법 및 검증

① 수집·정제: 파일명에서 frame_id를 추출해 센서와 정답을 연결한다. 누락·중복·비정상 좌표를 검사하고, 프레임·객체·포인트 정보를 명시적 스키마의 Parquet 테이블로 변환한다. 프레임 단위로 나누어 처리하여 전체 데이터를 메모리에 적재하지 않는다.

② 분석·조회: Spark DataFrame·SQL로 테이블을 결합하고, 공간 격자별 LiDAR 통계와 객체 종류·거리·가림별 분포를 집계한다. 3D 박스 내부 포인트 수를 계산하여 관측량이 적은 장면을 추출한다. 카메라·LiDAR·정답을 함께 확인하는 조건 검색 화면을 구현한다.

③ 정확성·성능: 동일한 집계 결과를 Python 순차 처리와 대조한다. 고정된 100·1,000·7,481개 장면에서 순차 처리와 Spark local[1/4/8]을 비교하고, 3회 실행의 중앙값·처리량·메모리 사용량을 기록한다. 단일 장비의 병렬 처리 효과와 초기화·입출력 비용을 함께 분석한다.

## 3. 예상 결과물 및 후속 확장

정제 데이터 생성 코드와 Parquet 테이블, 품질 검사 결과, 조건별 통계 그래프, 처리 성능 비교표, 장면 탐색 웹 화면을 완성한다. 소스와 실행·검증 방법을 함께 제출한다. 이후 사전 학습 객체 탐지 모델의 예측을 연결해 거리·가림 조건별 미검출 사례를 분석하는 도구로 확장한다.

## 4. 추진 일정 및 주요 단계

| 기간 | 주요 단계 및 완료 목표 |
|---|---|
| 10/21 | 제안서 제출 및 데이터·분석 범위 확정 |
| 10/22–11/1 | 표본 파일 해석·좌표 검증, 전체 학습 데이터 수집·검사 |
| 11/2–11/15 | Parquet 변환, Spark 집계 및 장면 특징 생성 |
| 11/16–11/29 | 정확성·성능 비교, 탐색 화면 및 분석 결과 완성 |
| 11/30–12/8 | 재현·검증 자료와 5분 발표 준비, 12/8 발표 |
| 12/9–12/15 | 최종 보고서·소스·검증 결과 정리 및 제출 |

데이터 출처: KITTI Vision Benchmark Suite · cvlibs.net/datasets/kitti/eval_object.php?obj_benchmark=3d